

Data Management RA

Documento descrittivo della reference architecture per il data management

Data

05 Feb 2025

Versione

1.0

Copyright

Questo documento appartiene ad Azienda Zero. I contenuti del medesimo – testi, tabelle, immagini, etc. – sono protetti ai sensi della normativa in tema di opere dell'ingegno. Tutti i diritti sono riservati. Il presente documento potrà essere utilizzato per la realizzazione di progetti regionali liberamente ed esclusivamente nel rispetto delle regole (standard) stabilite da Azienda Zero. Ogni altro utilizzo, compresa la copia, distribuzione, riproduzione, traduzione in altra lingua, potrà avvenire unicamente previo consenso scritto da parte di Azienda Zero. In nessun caso, comunque, il documento potrà essere utilizzato per fini di lucro o per trarne una qualche utilità.

ATTENZIONE

Ogni copia cartacea del presente documento si ritiene non controllata. È responsabilità di chi utilizza copie non controllate verificarne il livello di aggiornamento.

Info sul documento

Redazione

Data	Nominativo
05/2022	Azienda Zero
02/2025	Damiano Sette

1. Validazione

Data	Nominativo
05/2022	Azienda Zero
11/2022	Azienda Zero

Approvazione

Data	Nominativo
05/2022	Azienda Zero
11/2022	Azienda Zero

Registro delle Revisioni



Data	Versione	Descrizione	Nominativo
12/2022	0.1	Prima Stesura	Azienda Zero
05/2025	1.0	Revisione e implementazione AS IS - TO BE	Miriade
09/2025	1.1	Revisione struttura	Miriade - Reply

Sommario

Info sul documento	2
Sommario	4
Introduzione	6
Scopo del Documento e Destinatari	6
Processo di Revisione e Aggiornamento	6
Principi	7
Sicurezza	7
Sostenibilità	7
Interoperabilità	7
Centralità del Dato	8
Architettura Dati di Riferimento	8
Visione d'Insieme (AS-IS)	8
Evoluzione prevista (TO-BE)	9
Componenti Chiave e Stack Tecnologico	10
Datawarehouse OCI	10
Modello dati	10
Storage	10
Elaborazione	10
Data Lake AWS	11
Modello dati	11
Storage	12
Elaborazione	12
Standard e Vincoli Progettuali	12
Standard di Progettazione	13
Standard di Governance e Catalogazione	13
Strategie di integrazione	14
Green Field	14
Modello 1: ETL/Batch (Ingestion dei dati)	14
Modello 2: Data Virtualization (Accesso Federato)	14
Approccio Ibrido	15
Brown Field	15
Comunicazione tra strumenti	16
Principi Fondamentali di Sicurezza	16
Accesso alle Fonti Dati	16
Esposizione del Dato ai Consumatori	16
Richiesta esposizione WS Denodo	17

Tipologie di reportistica	17
Log Management	18
Architettura e Ambienti di lavoro	19
Concetti fondamentali	21
Data Governance	21
Data Fabric	21
Data Mesh	21
DataOps	22
Data Catalog	22
Data Lineage	23
Data Lake	23
Data Virtualization	24

Introduzione

Scopo del Documento e Destinatari

Il presente documento definisce la **Data Reference Architecture** di Azienda Zero.
Lo scopo è fornire ai **fornitori esterni** e ai **team di sviluppo** una linea guida chiara e standardizzata per la progettazione, la realizzazione e la gestione di soluzioni che trattano dati all'interno dell'ecosistema regionale.

Il documento stabilisce gli **standard di integrazione** e le **regole di utilizzo degli strumenti**, al fine di garantire:

- **coerenza architettuale** tra i diversi progetti
- **sicurezza e conformità normativa**
- **interoperabilità e sostenibilità** delle soluzioni
- **valorizzazione del dato** come patrimonio aziendale

Sono destinatari di questo documento:

- fornitori e partner esterni coinvolti nello sviluppo di soluzioni dati
- architetti e solution architect
- data engineer e sviluppatori ETL
- analisti dati e business intelligence specialist
- project manager e responsabili di progetto

L'adesione ai principi e agli standard qui definiti è **condizione necessaria** per l'approvazione e la messa in esercizio di qualsiasi nuova iniziativa progettuale.

Azienda Zero auspica che questo documento venga visto come un'opportunità per i fornitori, i quali, adattandosi al suo contenuto, possono agevolare il processo di integrazione e accelerare la fase di messa in produzione dei progetti.

Processo di Revisione e Aggiornamento

È essenziale considerare questo documento come un **punto di partenza** anziché di arrivo.
Eventuali miglioramenti, nuove tecnologie e metodologie proposte per potenziare la gestione del dato saranno oggetto di attenta valutazione. Di conseguenza, è importante percepire questo documento come **dinamico e soggetto a periodici aggiornamenti**.

Prima dell'avvio di un progetto, i fornitori sono tenuti a:

1. Verificare di possedere la **versione più aggiornata** del documento.
2. Seguire integralmente le prescrizioni in esso contenute.
3. Segnalare eventuali osservazioni o proposte di miglioramento al team Data Management di Azienda Zero.

Principi

L'architettura per la gestione del dato e le progettualità che lo coinvolgono devono seguire i principi generali di seguito elencati, supportati da pratiche di **Data Governance, Data Fabric e Data Mesh**, ove applicabili.

Il rispetto di tali principi è **obbligatorio** per tutti i fornitori e costituisce criterio di approvazione dei progetti.

Sicurezza

- **Confidenzialità:** I dati devono essere protetti da accessi non autorizzati. È obbligatorio implementare policy e permessi basandosi sul principio del least privilege e classificare ogni dataset con il livello di riservatezza appropriato
- **Integrità:** I dati devono essere protetti da modifiche non autorizzate
- **Disponibilità:** I dati devono essere disponibili quando necessario
- **Conformità:** La gestione dei dati deve rispettare le normative vigenti. Il fornitore è tenuto a garantire che ogni processo sia conforme a GDPR e alle policy di sicurezza di Azienda Zero
- **Tracciabilità:** Le attività di accesso e modifica devono essere tracciabili

Sostenibilità

- **Efficienza:** L'architettura deve essere efficiente in termini di costi e risorse, evitando sprechi
- **Scalabilità:** L'architettura deve essere in grado di scalare per supportare la crescita dei dati e delle esigenze di business
- **Etica:** La gestione dei dati deve essere etica e rispettare i diritti degli individui

Interoperabilità

- **Integrazione:** I dati e le infrastrutture che li contengono devono essere facilmente integrabili tra i diversi sistemi aziendali per consentire agevoli migrazioni, upgrade e spostamenti
- **Standardizzazione:** L'architettura deve essere implementata ove possibile seguendo gli standard proposti o riutilizzare infrastrutture esistenti qualora siano in linea con i requisiti di prestazione e di segregazione
- **Accessibilità:** I dati devono essere accessibili agli utenti autorizzati in modo semplice e

sicuro, sempre limitando gli accessi alle sole operazioni necessarie

Centralità del Dato


- **Orientamento al business:** L'architettura dei dati deve essere allineata alle esigenze di business e supportare il raggiungimento degli obiettivi aziendali
- **Adattabilità e flessibilità:** L'architettura deve essere in grado di adattarsi ai cambiamenti del business e alle nuove tecnologie
- **Semplicità e chiarezza:** L'architettura deve essere semplice da comprendere e da utilizzare, favorendo l'adozione da parte di tutti gli utenti
- **Innovazione:** L'architettura deve promuovere l'innovazione e l'utilizzo di nuove tecnologie per la gestione dei dati

L'implementazione di questi principi sarà guidata dai fondamenti di **Data Governance**.

Architettura Dati di Riferimento

Visione d'Insieme (AS-IS)

Le scelte infrastrutturali attuali hanno portato alla definizione del seguente disegno:



Ad oggi il mondo dell'analisi dati in A0 prevede tre principali metodologie di ingestion del dato finalizzata ad analisi e reportistica.

1. **GeFIS-DWH:** trasmissione dei dati dei flussi sanitari tramite portale GeFIS. I dati

vengono successivamente controllati, anonimizzati, consolidati in GeFIS e utilizzati per l'alimentazione del DWH. L'infrastruttura GeFIS e DWH è sviluppata on premise su tecnologia SAS, ma è in corso un progetto di reingegnerizzazione in cloud OCI.

Attualmente gli strumenti di reportistica e interrogazione del dato sfruttano la tecnologia SAS on premise. Per alcuni ambiti ridotti, per esigenze di business nate in passato, la parte di analisi e reportistica viene eseguita tramite GCP oppure in Qlik.


2. **Data Lake:** elaborazione batch o real-time di dato proveniente dal DWH oppure in alcuni casi direttamente da alcune fonti dato in AWS. L'obiettivo è costruire un data lake in S3 affiancato dal catalog di Glue e che sfrutti gli strumenti di analisi di AWS per preparare ed elaborare il dato e renderlo disponibile ai vari utenti o applicativi di Azienda Zero secondo le opportune modalità.
3. **Data Virtualization:** layer Denodo per l'esposizione di dati in tempo reale e on demand.

I dati di log seguono un percorso distinto, in quanto vengono trattati e gestiti attraverso il sistema di **Log Management**. Per maggiori dettagli, si rimanda al paragrafo dedicato.

Lo strumento di Data Catalog è in fase di inserimento e andrà progressivamente a connettersi a tutte le fonti dato per creare il catalog completo di tutti i flussi aziendali.

Evoluzione prevista (TO-BE)

A tendere l'ecosistema Data Management evolverà nel seguente schema:



Il portale GeFIS verrà sostituito da un nuovo portale di accoglienza, mentre l'ETL dei flussi sanitari, attualmente implementato su tecnologia SAS, verrà progressivamente reingegnerizzato su infrastruttura cloud OCI. La reportistica verrà sviluppata con Visual Analytics in SAS Viya e su Oracle Analytics, mentre gli strumenti per l'analisi dei dati saranno SAS Studio in SAS Viya e DBeaver Team.

Verrà completata l'adozione della struttura di Log Management eliminando definitivamente logz.io. Denodo diventerà layer in cui eseguire anonimizzazione e Data Masking a prescindere dal tipo di analisi precedente, virtualizzando il dato per la reportistica.

Componenti Chiave e Stack Tecnologico

Datawarehouse OCI

Nel seguente paragrafo descriveremo le componenti chiave e stack tecnologico del Datawarehouse TO-BE, quindi su infrastruttura cloud OCI.

Modello dati

Il DWH in OCI, sarà composto da 3 principali layer:

- 1. Acquisition Layer:** Si occuperà dell'acquisizione dei dati da fonti esterne, del caricamento dati su ADW e delle operazioni di standardizzazione, controllo, pseudo-anonimizzazione e ufficializzazione.
- 2. Integration Layer:** Si occuperà di gestire le operazioni di arricchimento e pulizia del dato acquisito nel layer precedente con lo scopo di preparare il dato rendendolo adatto alle operazioni di business.
- 3. Business Layer:** Si occuperà di gestire le operazioni legate alla logica di business del Datawarehouse.

Storage

I servizi centrali per lo storage di dati sono i seguenti:

- **OCI Object Storage** (Buckets) per lo storage di file non strutturati.
- **Autonomous Data Warehouse (ADW)** per lo storage di dati strutturati (tabellari).

Elaborazione

I servizi OCI che saranno utilizzati per l'elaborazione nel Datawarehouse OCI sono:


- **OCI Data Integration:** servizio per la progettazione ed esecuzione di pipeline ETL con l'ausilio di apposita UI
- **OCI Functions:** servizio serverless per l'esecuzione di codice in risposta ad eventi o richieste (event-driven).

L'adozione di strumenti aggiuntivi potrà essere valutata in base alle esigenze specifiche di ciascun progetto e richiederà l'**approvazione preventiva** da parte del gruppo Data Management nell'ambito del processo di validazione.

Data Lake AWS

Modello dati

Il data Lake sarà composto da più livelli, alla base vi è un livello generale in cui vengono raccolti i dati grezzi, esattamente come forniti dalle fonti originarie. Su questi i dati vengono elaborati e trasformati in funzione delle esigenze particolari creando così dei livelli più specifici.



Il repository centrale è **Amazon S3**, che raccoglie sia dati grezzi sia dati lavorati.

Il formato **standard** per i dati raffinati è **Parquet**, per i vantaggi in termini di efficienza, compressione, ottimizzazione delle query e riduce i costi di storage. Tuttavia, si tiene conto delle esigenze specifiche:

- Se il dato viene fornito direttamente in formato Parquet, viene accettato e integrato più rapidamente.

- Se il dato viene fornito in altri formati (es. CSV, Excel, JSON, ...), viene attivata una pipeline di trasformazione ETL per uniformarlo agli standard architetturali definiti.

I dati devono sempre essere caricati in area **raw** prima di qualsiasi trasformazione.

Storage

Il principale servizio di storage utilizzato all'interno del Lake è S3. In affiancamento ad esso, per specifici progetti possono essere utilizzati altri servizi tra cui Amazon Redshift e RDS.

Elaborazione

I servizi AWS standard coinvolti nella definizione del data lake sono:

- **AWS Glue** è lo strumento standard per pipeline ETL complesse.
- **AWS Lambda** è ammesso per orchestrazioni leggere o trasformazioni puntuali e event-driven.
- L'introduzione di strumenti aggiuntivi (es. RDS, schemi Redshift, bucket secondari) potranno essere introdotti sulla base delle necessità specifiche dei singoli progetti e devono essere **preventivamente approvati** dal gruppo Data Management nell'iter di validazione.

Il dato può essere acquisito nel Data Lake attraverso **tre modalità principali**:

1. **Recupero del dato**: tramite connessione criptata jdbc o chiamata API sfruttando gli strumenti di integrazione di AWS menzionati in precedenza.
2. **Deposito dall'esterno**: un'applicazione può scrivere direttamente nel Data Lake, depositando i dati all'interno di un bucket predefinito. In questo caso deve essere concordato il tracciato dei file depositati ed ogni modifica a tale tracciato deve essere opportunamente comunicata al gruppo Data Management.
3. **Utenti autorizzati**: in casi specifici, anche gli utenti possono caricare manualmente dati nel Data Lake.

Questo approccio garantisce il rispetto delle best practice di gestione del dato, mantenendo al contempo la flessibilità necessaria per supportare fonti eterogenee.

Standard e Vincoli Progettuali

In questo capitolo sono elencati i requisiti e gli standard che i progettisti e gli sviluppatori devono obbligatoriamente seguire nello sviluppo di qualsiasi componente o flusso che tratti

dati all'interno dell'ecosistema di Azienda Zero. Il rispetto di questi vincoli è fondamentale per garantire la manutenibilità, la sicurezza e la coerenza del patrimonio informativo.

Standard di Progettazione

- **Separazione tra dati grezzi e dati elaborati:** ogni dato viene conservato nella forma originaria prima di ogni trasformazione, garantendo tracciabilità e riproducibilità.
- **Formati ottimizzati:** pur accettando in input e lettura dati in diversi formati, è sempre preferibile l'utilizzo di un formato ottimizzato come Parquet.
- **Naming convention coerenti:** i percorsi nei bucket e i nomi degli oggetti devono rispettare gli standard aziendali.
- **Versionamento:** ogni rilascio di dati elaborati e script ETL deve essere versionato e validato prima della pubblicazione.
- **Accesso controllato:** tutti gli accessi devono essere governati da policy IAM granulari, secondo il principio del least privilege.
- **Automazione e riuso:** i fornitori devono privilegiare soluzioni modulari, automatizzate e riutilizzabili, minimizzando l'intervento manuale.

Standard di Governance e Catalogazione

- **Censimento Obbligatorio:** Tutti i nuovi flussi dati, dataset, report e altri asset informativi devono essere obbligatoriamente censiti nel Data Catalog aziendale, non appena questo sarà operativo.
- **Metadati Minimi Richiesti:** Per ogni asset censito, è obbligatorio fornire almeno i seguenti metadati, come già definito nel documento:
 - **Data Owner:** Il responsabile di business del dato.
 - **Data Steward:** Il referente operativo e qualitativo.
 - **Descrizione Funzionale:** Una spiegazione chiara di cosa rappresenta il dato.
 - **Fonte Originaria:** Il sistema da cui il dato proviene.
 - **Classificazione di Sicurezza:** Il livello di confidenzialità del dato (es. Pubblico, Interno, Riservato).
- **Tracciamento del Data Lineage:** È obbligatorio mappare e documentare il **Data Lineage**, ovvero il percorso completo che un dato compie dalla sua origine fino alla sua fruizione finale. Questo include ogni passaggio di trasformazione, aggregazione o copia. Il lineage è essenziale per l'analisi degli impatti, il troubleshooting e per garantire l'affidabilità del dato.

La sezione "Concetti fondamentali" alla fine di questo documento fornisce ulteriori dettagli su cosa si intende per Data Catalog e Data Lineage.

Strategie di integrazione

La modalità per fornire il dato in Azienda Zero può variare a seconda di una serie di caratteristiche.

Si precisa che la valutazione di apertura della comunicazione tra network differenti è demandata al gruppo ITOps e Change.

Si distinguono due categorie per l'integrazione. Quando questa integrazione è già presente (brown field) oppure quando è una nuova integrazione/nuovo applicativo (green field)

Green Field

Per ogni nuova integrazione (progetto Green Field), la scelta della corretta strategia è fondamentale per garantire performance, sicurezza e sostenibilità. La decisione deve essere guidata dalla natura del dato, dalla frequenza di aggiornamento richiesta e dal caso d'uso finale (reportistica o applicativo).

Azienda Zero adotta due modelli di integrazione principali e complementari: **ETL/Batch** per l'ingestion massiva nel Data Lake e **Data Virtualization** per l'accesso federato in tempo reale.

Modello 1: ETL/Batch (Ingestion dei dati)

Questo modello prevede l'estrazione, la trasformazione e il caricamento (ETL) dei dati all'interno del layer di analisi di A0 (DWH e Data Lake). È la soluzione da privilegiare per preparare dati ottimizzati per analisi complesse e reportistica.

Scegliere questo modello quando:

- I **dati sono massivi** e devono essere storicizzati e analizzati nel tempo.
- Le **trasformazioni sono complesse** (join, aggregazioni, pulizia avanzata) e richiedono una preparazione a monte per non sovraccaricare gli strumenti di front-end.
- La **frequenza di aggiornamento non è real-time** (es. giornaliera, settimanale, mensile).
- Il dato finale deve essere **consolidato e riutilizzato** da più report o applicazioni senza interrogare ripetutamente le fonti originali.
- Si vuole creare un **livello di dati incrementale** per consolidare le informazioni ed evitare rielaborazioni superflue.

Modello 2: Data Virtualization (Accesso Federato)

Questo modello utilizza lo strumento di virtualizzazione (Denodo) per esporre e integrare dati provenienti da fonti diverse **senza spostarli fisicamente**. Funge da layer di disaccoppiamento, sicurezza e accesso unificato.

Scegliere questo modello quando:

- È richiesto un **accesso ai dati in tempo reale** (real-time) direttamente dalle fonti di produzione (es. metriche e KPI operativi).
- I dati **non possono essere replicati** nel Data Lake per motivi normativi, di sicurezza o perché di proprietà esterna (es. dati delle AULSS).
- L'integrazione richiesta è **puntuale e on-demand** per arricchire un applicativo con informazioni "fresche".
- È necessario applicare **regole di sicurezza** dinamiche come Data Masking, anonimizzazione o Row-Level Security prima di esporre il dato agli utenti finali.

Approccio Ibrido

L'utilizzo di entrambe le procedure non è mutuamente esclusivo ma esiste la possibilità di utilizzarle in combinazione per adempiere al risultato finale nel modo ottimale. Un caso d'uso comune prevede:

1. **ETL/Batch** per consolidare e storicizzare i dati massivi nel Data Lake o nel DWH.
2. **Data Virtualization** per federare tali dati con altre fonti real-time, applicando un ulteriore strato di sicurezza e astrazione prima dell'esposizione finale.

Brown Field

Per le integrazioni già esistenti (progetti Brown Field), l'approccio richiede un'analisi degli impatti e delle architetture in uso.

L'obiettivo è allineare progressivamente queste soluzioni agli standard definiti per i progetti Green Field. Sono accettate e incoraggiate progettualità a step, che prevedano ad esempio una prima fase di consolidamento dei dati nel DWH o Data Lake tramite ETL, seguita da un'evoluzione che introduca il layer di virtualizzazione per standardizzare l'accesso e la sicurezza.

Ogni intervento su un'integrazione esistente deve essere valutato per cogliere l'opportunità di adeguarlo a questa Reference Architecture.

Comunicazione tra strumenti

Questa sezione definisce gli standard tecnici e di sicurezza obbligatori per la comunicazione tra i vari componenti dell'architettura dati (ETL, DWH, Data Lake, Data Virtualization, BI). Ogni integrazione deve rispettare le seguenti regole per garantire la sicurezza, la tracciabilità e la governance degli accessi.

Principi Fondamentali di Sicurezza

- **Principio del Least Privilege:** L'accesso a qualsiasi risorsa (object storage, database, viste) deve essere governato dal principio del "privilegio minimo". Ogni utente o servizio applicativo potrà accedere solo ed esclusivamente alle informazioni strettamente necessarie per le proprie funzioni. Non sono ammesse utenze generiche o policy eccessivamente permissive.
- **Utenze Applicative Dedicate:** Le connessioni a database e altre fonti dati devono avvenire esclusivamente tramite utenze applicative dedicate (service account). Non è consentito l'uso di credenziali personali per i processi automatici.
- **Comunicazioni Cifrate:** Tutte le connessioni devono utilizzare, ove tecnicamente possibile, protocolli di comunicazione sicuri e cifrati (es. JDBC con crittografia, chiamate API su HTTPS).

Accesso alle Fonti Dati

- **Connessioni a Database:** L'accesso a fonti dati relazionali o di altra natura da parte di strumenti ETL (AWS Glue, Lambda, OCI DIS, OCI Functions) o di virtualizzazione (Denodo) deve avvenire tramite connessione JDBC/ODBC criptata o nativa Oracle TCP/SSL criptata, utilizzando le utenze applicative dedicate.
- **Accesso a Object Storage:** Il conferimento di dati tramite file (es. da parte di applicativi esterni o caricamenti manuali) deve avvenire depositando i file in uno degli storage definiti nel DWH o nel Data Lake predefinito e dedicato. Gli accessi a tale object storage saranno gestiti esclusivamente tramite policy IAM granulari.

Esposizione del Dato ai Consumatori

- **Modalità Standard - Web Service via Denodo:** La modalità preferenziale e standard per esporre dati a strumenti di visualizzazione o ad altri applicativi è attraverso i Web Service (API REST) pubblicati da Denodo. Questo approccio garantisce disaccoppiamento, sicurezza centralizzata e governance degli accessi.
- **Modalità Alternativa - Accesso Diretto:** In casi specifici, qualora gli strumenti di visualizzazione risiedano nello stesso account di storage del dato e vi siano comprovate

esigenze di performance, è consentito l'accesso diretto a tali dati tramite interrogazione diretta e connessioni opportunamente secretate. Tale modalità deve essere preventivamente approvata dal team Data Management.

Richiesta esposizione WS Denodo

Per ottenere l'esposizione di un dato tramite Web Service su Denodo, il fornitore deve seguire la seguente procedura:

1. Inviare una richiesta formale al gruppo Data Management, specificando la fonte dati, i campi richiesti e la logica di estrazione
2. A seguito dell'approvazione, il gruppo Data Management creerà la vista e il Web Service su Denodo
3. Inviare una richiesta al gruppo ITOps per l'apertura delle rotte di rete (firewall) dagli IP sorgenti e per il censimento dell'utenza applicativa client
4. ITOps fornirà le credenziali (client_id, client_secret) e gli endpoint necessari per l'autenticazione e la chiamata al servizio

Chiamata autenticazione	<pre>curl -X POST <endpoint-dav-cognito> -H "Content-Type: application/x-www-form-urlencoded" -d "grant_type=client_credentials&client_id=<id_client> &client_secret=<id_secret>&scope=<scope>"</pre>
Chiamata estrazione	<pre>curl -X GET "<endpoint_denodo>/<nome_db>/<nome_ws>/views/<nome_vista>[?field=value]" -H "Authorization: Bearer <token*>" -H "Accept:application/json" [-H "Accept-Encoding: gzip, deflate"]</pre>

Tipologie di reportistica

Azienda Zero ha standardizzato l'adozione di specifici strumenti di visualizzazione per rispondere in modo efficace a diverse esigenze di analisi e a diverse tipologie di utenza. La scelta dello strumento per un nuovo progetto non è arbitraria, ma deve seguire le indicazioni riportate di seguito, in base alla fonte dei dati e al caso d'uso.

La seguente tabella riassume gli standard di utilizzo per ciascuno strumento.

Strumento	Dominio di utilizzo principale	Fonte dati tipica	Utenza di riferimento	Note e vincoli
Tableau Server	Business Intelligence e Data Visualization self-service	Data Lake AWS (via Athena o Redshift), Data Virtualization (Denodo)	Utenti di business, analisti, management	Strumento standard per la creazione e condivisione di dashboard interattive a un'ampia platea di utenti. Offre il vantaggio di una distribuzione capillare grazie a licenze di sola lettura
SAS Visual Analytics / Oracle Analytics Cloud	Analisi su dati di DWH	Data Warehouse (SAS, OCI)	Utenti specialisti dell'area DWH, analisti statistici	Utilizzato specificamente per la reportistica basata sui dati consolidati nel DWH aziendale
Qlik	Analisi dati esplorativa e specifica	Varie (fonti dati dedicate)	Gruppi di utenti specifici con esigenze di analisi particolari	Soluzione impiegata per casistiche di analisi mirate
Grafana	Monitoraggio tecnico e operativo	Sistema di Log Management	Team IT Operations, Sviluppatori, Referenti tecnici di servizio	Esclusivamente dedicato all'analisi di log, metriche di sistema e monitoraggio delle performance applicative. Non deve essere utilizzato per la reportistica di business

La scelta dello strumento di reportistica per un nuovo progetto deve essere preventivamente discussa e approvata dal team Data Management di Azienda Zero per garantire coerenza con gli standard architetturali.

Log Management

Log Management è il sistema adottato da **Azienda Zero** per la **raccolta, gestione e monitoraggio centralizzato dei log** applicativi e di sistema. La soluzione è progettata per consentire la **visualizzazione e l'analisi integrata di log eterogenei**, provenienti da progetti e applicazioni diverse, con l'obiettivo di rilevare rapidamente malfunzionamenti, accessi e anomalie.

Il sistema si basa su **tecnologie AWS** e si articola in tre componenti principali:

- un **log collector**, che riceve i log tramite integrazioni applicative o di sistema, esegue parsing e arricchimento dei dati;

- un **database di raccolta** ad alta affidabilità dove i log vengono conservati per la consultazione e l'archiviazione;
- una piattaforma di **dashboarding e analisi**, realizzata con **Amazon Managed Grafana**, che consente la creazione di visualizzazioni personalizzate e la configurazione di alert via email.

Il sistema gestisce due principali **tipologie di log**:

- **Log analytics**: log applicativi destinati al monitoraggio dei servizi nei vari ambienti (on-premise e AWS), elaborati in near real-time;
- **Log audit**: log relativi agli accessi e alle operazioni critiche su applicazioni e infrastrutture, gestiti con vincoli di **immutabilità e versionamento** su AWS S3 in modalità WORM (Write Once Read Many).

Oltre alle funzionalità di base, Log Management supporta anche:

- servizi di **storage immutabile** per la conservazione sicura dei log audit;
- **API Gateway** per l'invio strutturato dei log da applicazioni esterne;
- **servizi di validazione** dei file per garantirne l'integrità e la non manipolazione.

Per tutti gli aspetti tecnici, i formati previsti, le modalità di onboarding, gli ambienti e le configurazioni da adottare, si rimanda al documento specifico di integrazione allegato:

[Documento di integrazione Log Management](#)

Architettura e Ambienti di lavoro

Il fornitore deve presentare una proposta architetturale che descriva in dettaglio le fonti dati, le trasformazioni previste, le tecnologie utilizzate e la destinazione dei dati. Per Azienda Zero sono previsti i documenti di RFC, MI e SA. Tali documenti saranno oggetto di revisione e approvazione dal comitato architetturale che si avvarrà dell'aiuto del gruppo Data Management di Azienda Zero.

Per lo sviluppo e la validazione dei flussi di dati e della reportistica può essere necessario avere a disposizione un ambiente segregato in cui configurare le policy, i permessi e le autorizzazioni in autonomia.

Altrettanto necessario può essere un ambiente in cui verificare i risultati raggiunti sfruttando dati reali e ove possibile di produzione, sempre in conformità con le normative sulla privacy vigenti. La quadratura dei risultati è da ritenersi parte integrante del lavoro di sviluppo.

Nel caso in cui la progettualità preveda il salvataggio di dati elaborati all'interno di un database o di un bucket di produzione sarà necessario fornire accessi di lettura agli operatori per verificare il corretto funzionamento e la qualità del dato prodotto, anche nell'ottica di fornire supporto ad eventuali segnalazioni dal business.

Concetti fondamentali

Questa sezione introduce i concetti chiave che costituiscono il lessico di base per qualsiasi attività in ambito dati. Comprendere e utilizzare correttamente questi termini è indispensabile per collaborare in modo efficace con l'ecosistema aziendale e con i suoi strumenti.

Data Governance

La data governance definisce regole, ruoli e processi per assicurare che i dati siano affidabili, accessibili e gestiti in modo sicuro.

In pratica significa stabilire chi può fare cosa, con quali dati e con quali strumenti. I benefici includono:


- conformità normativa
- riduzione dei rischi legati a dati sensibili
- miglioramento della qualità e tracciabilità del dato

Strumenti chiave: **data catalog** e **data lineage**.

Data Fabric


Il data fabric è un'architettura che collega in modo intelligente e sicuro tutte le fonti dati, indipendentemente da dove si trovino.

Consente di accedere e gestire i dati in modo unificato, automatizzando sicurezza e governance.




Data Mesh

Il data mesh propone un modello **distribuito**: ogni dominio (es. farmaci, acquisti, contabilità) è responsabile dei propri dati, trattandoli come “prodotti” riutilizzabili.



DataOps

Il DataOps applica i principi DevOps al mondo dei dati, con l'obiettivo di **velocizzare lo sviluppo e il rilascio di pipeline e analisi**, mantenendo controllo e qualità.



Data Catalog

Il **data catalog** è lo strumento che consente di censire, descrivere e rendere accessibili le fonti dati aziendali. Rappresenta una mappa strutturata del patrimonio informativo, utile a individuarne contenuti, significato, relazioni, responsabili e modalità d'uso.


Il catalogo è il punto di riferimento per:

- verificare se un dataset è già esistente
- attribuire ruoli e responsabilità (data owner, steward)
- garantire la qualità e l'aggiornamento delle informazioni
- tracciare il ciclo di vita dei dati

Il catalogo consente a figure tecniche e business di parlare un linguaggio comune, favorendo collaborazione e condivisione.

Data catalog software features

Data catalog software combines data governance principles and metadata management practices to deliver curated data sets to business analytics users. Here are 10 features it offers.



Data Lineage

Il **data lineage** descrive il percorso che un dato compie dalla sua origine fino alla sua fruizione, evidenziando ogni passaggio di trasformazione, copia, aggregazione o derivazione.

In termini pratici, permette di:

- comprendere l'origine di ogni campo visualizzato in un report
- identificare rapidamente errori o incoerenze
- ottimizzare i processi di manutenzione

Nel nostro contesto, è integrato con strumenti di catalogazione e visualizzato tramite grafi interattivi, per rendere il flusso dei dati trasparente e tracciabile.




Data Lake

Il **data lake** è un'area di archiviazione che consente di raccogliere grandi volumi di dati eterogenei (strutturati, semi-strutturati, non strutturati) in formato nativo.

Viene utilizzato per:

- centralizzare e conservare dati provenienti da più fonti
- alimentare analisi esplorative o avanzate
- separare lo storage dal calcolo, garantendo scalabilità

I dati possono essere interrogati on demand o trasformati al momento della lettura (*schema-on-read*), senza dover definire a priori uno schema rigido.



Data Virtualization

La **data virtualization** consente di esporre dati provenienti da sistemi diversi come se fossero un'unica sorgente, senza copiarli né replicarli. È una soluzione particolarmente efficace nei casi in cui:

- non è possibile replicare i dati per motivi di volume, frequenza o riservatezza
- si desidera accedere a dati in real time, mantenendo le fonti aggiornate
- si vuole standardizzare l'accesso alle fonti eterogenee

Lo strumento adottato (es. Denodo) consente la creazione di viste virtuali documentate e protette, che possono essere riutilizzate da diversi progetti o reparti.

